EnglishVO API課金レポート（更新版）

生成日: 2026-03-01 | 為替レート: $1 = ¥150（デフォルト）

1. 使用モデルと単価一覧

プロバイダ	モデル	入力 (USD/1Mトークン)	出力 (USD/1Mトークン)	用途
Google	gemini-2.5-flash	$0.30	$2.50	画像からの単語抽出（Vision）
OpenAI	gpt-4o-mini	$0.15	$0.60	テキスト生成全般（クイズ、翻訳、インサイト等）
OpenAI	gpt-4o	$2.50	$10.00	ディクテーション採点のフォールバック（UI削除済み）
OpenAI	text-embedding-3-small	$0.02	—	セマンティック検索用ベクトル生成

2. API課金発生箇所の全一覧

2-1. 画像スキャン（単語抽出）

エンドポイント	アクセス	モデル	概要	推定コスト/回
/api/extract	Free Pro	gemini-2.5-flash	同期スキャン。画像1枚をAIで解析し、英単語リストをJSON抽出。Freeユーザー専用（Proはバックグラウンドに統一済み）。	¥0.3〜1.0
/api/scan-jobs/process	Pro	gemini-2.5-flash + gpt-4o-mini + text-embedding-3-small	バックグラウンドスキャンジョブ。画像抽出→クイズ生成→インサイト生成→Embedding生成を一括実行。最もコストが高い単一操作。	¥1.5〜8.0 / ジョブ 画像枚数・単語数で変動

※ スキャンモードにより使用プロンプトが異なるが、モデルは全モード共通で gemini-2.5-flash。
※ Cloud Runゲートウェイ経由の場合、Gemini失敗時にOpenAI gpt-4o-miniへフォールバック。

2-2. クイズ誤答選択肢の再生成

エンドポイント	アクセス	モデル	概要	推定コスト/回
/api/regenerate-distractors	Free Pro	gpt-4o-mini	4択クイズの不正解選択肢3つを再生成。	¥0.01〜0.03

2-3. 例文生成

エンドポイント	アクセス	モデル	概要	推定コスト/回
/api/generate-examples	Free Pro	gpt-4o-mini	英単語に対する例文（英文+和訳）を生成。日次制限あり（Free: 5回, Pro: 50回）。	¥0.01〜0.03

2-4. 翻訳

エンドポイント	アクセス	モデル	概要	推定コスト/回

/api/translate	Free Pro	gpt-4o-mini	英→日翻訳。日次制限あり（Free: 10回, Pro: 100回）。	¥0.005〜0.02

2-5. 単語インサイト生成

エンドポイント	アクセス	モデル	概要	推定コスト/回
/api/generate-word-insights	Pro	gpt-4o-mini	品詞タグ、関連語、使用パターンを生成。まず無料辞書APIで情報取得し、AIで構造化。日次制限あり（Pro: 100回）。 表示先: /project/[id]/insights	¥0.02〜0.05 / 単語

2-6. Embedding生成（セマンティック検索用）

エンドポイント	アクセス	モデル	概要	推定コスト/回
/api/embeddings/sync	Pro	text-embedding-3-small	単語のベクトルを一括生成・同期。バッチ処理。	¥0.001〜0.01 / バッチ
/api/search/semantic	Pro	text-embedding-3-small	検索クエリをEmbedding化し、pgvectorで類似単語を取得。	¥0.0003 / クエリ

2-7. UI削除済み機能（APIルートは残存）

エンドポイント	ステータス	モデル	旧機能	旧推定コスト/回
~~/api/sentence-quiz~~	UI削除済	~~gpt-4o-mini~~	~~例文クイズ（穴埋め・語順並べ替え・複数穴埋め）。1回のリクエストで複数のAI呼び出し。~~	~~¥0.3〜1.5~~
~~/api/sentence-quiz/lite~~	UI削除済	~~gpt-4o-mini~~	~~例文クイズ（バッチ版）。単一AI呼び出しで複数問生成。~~	~~¥0.05〜0.15~~
~~/api/dictation/grade~~	UI削除済	~~gpt-4o-mini (fallback: gpt-4o)~~	~~ディクテーション画像の採点。Vision APIで手書き文字を解析。~~	~~¥0.05〜0.5~~

※ 上記3エンドポイントはUIからの導線を削除済み。APIルート自体はコードベースに残存（将来復活の可能性あり）。
※ scan-jobs/process内の例文クイズプリ生成も同時に削除済み。

---

3. ユーザー操作別コスト目安

#	ユーザー操作	呼ばれるAPI	推定コスト (JPY)
1	画像1枚スキャン（Free・同期）	/api/extract	¥0.3〜1.0
2	画像1枚スキャン（Pro・バックグラウンド）	scan-jobs/process (抽出+クイズ+インサイト+Embedding)	¥1.5〜4.0
3	画像5枚スキャン（Pro・バックグラウンド）	scan-jobs/process × 5画像並列	¥5.0〜15.0
4	画像20枚スキャン（Pro・バックグラウンド）	scan-jobs/process × 20画像	¥15.0〜50.0
5	クイズ選択肢の再生成	/api/regenerate-distractors	¥0.01〜0.03
6	例文生成 (1単語)	/api/generate-examples	¥0.01〜0.03
7	翻訳 (1回)	/api/translate	¥0.005〜0.02
8	単語インサイト生成 (1単語)	/api/generate-word-insights	¥0.02〜0.05

9	セマンティック検索 (1クエリ)	/api/search/semantic	¥0.0003
10	Embedding一括同期 (50語)	/api/embeddings/sync	¥0.005〜0.01

4. コストが高い順ランキング（アクティブ機能のみ）

順位	機能	主要モデル	コスト要因	1回あたり目安
1	バックグラウンドスキャン（複数画像）	gemini-2.5-flash + gpt-4o-mini + embedding	画像枚数 × (抽出+後処理)	¥1.5〜50.0
2	画像スキャン（同期・Free）	gemini-2.5-flash	Vision API呼び出し	¥0.3〜1.0
3	単語インサイト生成	gpt-4o-mini	辞書API + AI構造化	¥0.02〜0.05
4	例文生成	gpt-4o-mini	短いテキスト生成	¥0.01〜0.03
5	クイズ選択肢再生成	gpt-4o-mini	短いテキスト生成	¥0.01〜0.03
6	翻訳	gpt-4o-mini	短いテキスト生成	¥0.005〜0.02

5. コスト管理の仕組み

5-1. APIコスト記録

全AI呼び出しは `recordApiCostEvent()` (`src/lib/api-cost/recorder.ts`) を通じて `api_cost_events` テーブルに記録される。プロバイダ、モデル、トークン数、推定コスト（USD/JPY）を保存。

5-2. 利用制限

- **スキャン回数制限:** Free: 3回/日、Pro: 無制限（`check_and_increment_scan` RPC）
- **単語数制限:** Free: 100語上限（`FREE_WORD_LIMIT`）
- **各API日次制限:** `checkAndIncrementFeatureUsage()` で管理。例文生成(Free:5/Pro:50)、翻訳(Free:10/Pro:100)、インサイト(Pro:100)等。

5-3. AI設定一元管理

`src/lib/ai/config.ts` でモデル・プロバイダ・温度・最大トークンを一元設定。
Cloud Runゲートウェイ (`cloud-run-scan/`) がGemini→OpenAIフォールバックを実装。

6. 今回の変更によるコスト影響

6-1. Proスキャンパイプライン統一

Proユーザーのスキャンを一律バックグラウンドジョブに統一。同期パス(`/api/extract`)へのフォールバックを廃止。
コスト影響: AI呼び出し内容は同一のため、APIコストの増減なし。

6-2. 例文クイズ・ディクテーションのUI削除

UIからの導線を削除したことで、以下のAPI呼び出しが実質的に発生しなくなる:

- `/api/sentence-quiz` — 旧コスト: ¥0.3〜1.5/回
- `/api/sentence-quiz/lite` — 旧コスト: ¥0.05〜0.15/回
- `/api/dictation/grade` — 旧コスト: ¥0.05〜0.5/回
- `scan-jobs/process` 内の例文クイズプリ生成 — バックグラウンドスキャン時の後処理から除外

コスト影響: 削減方向。特にヘビーユーザーが例文クイズを頻繁に使用していた場合に効果大。

EnglishVO API Cost Report v2 — Generated 2026-03-01