MERKEN AI APIコスト分析

使用モデルと料金

モデル	用途	Input ($/1M tokens)	Output ($/1M tokens)
Gemini 2.5 Flash	OCR画像抽出	$0.30	$2.50
GPT-4o-mini	クイズ生成・例文・翻訳等	$0.15	$0.60
text-embedding-3-small	セマンティック検索用	$0.02	—

> *為替レート: $1 = ¥150 で換算*

導線1: スキャン（写真 → 単語抽出 → 保存）

1枚の写真から約15単語を抽出する想定。

ステップ	モデル	Input tokens	Output tokens	コスト (¥)
OCR抽出	Gemini 2.5 Flash	~1,550	~1,500	¥0.63
ディストラクター + 例文生成	GPT-4o-mini (batch)	~1,300	~1,800	¥0.19
Word Insights *(Pro)*	GPT-4o-mini ×15	~12,000	~6,000	¥0.81
Embeddings同期 *(Pro)*	embedding-3-small	~500	—	≈¥0

- **Freeユーザー: ¥0.8 / 回**
- **Proユーザー: ¥1.6 / 回**

導線2: クイズ（4択, 10問）

ディストラクターがスキャン時に生成済みなら **コスト¥0**。未生成の単語がある場合のみ発生。

ステップ	モデル	Input tokens	Output tokens	コスト (¥)
ディストラクター補完 (1単語)	GPT-4o-mini	~950	~150	¥0.03

※ Input の大半はシステムプロンプト (~900 tokens)。単語データは ~50 tokens。

- **通常: ¥0 / 回（生成済み）**
- **最大: ¥0.03 / 回（未生成時、1単語あたり）**

導線3: 手動単語追加（1単語）

Share Target経由またはプロジェクト内での手動追加。

ステップ	モデル	Input tokens	Output tokens	コスト (¥)
ディストラクター + 例文生成	GPT-4o-mini	~950	~150	¥0.03
Word Insights *(Pro)*	GPT-4o-mini	~800	~400	¥0.05

- **Freeユーザー: ¥0.03 / 回**
- **Proユーザー: ¥0.08 / 回**

導線4: 単語編集（Pro限定, 1単語）

日本語訳や英単語を変更した際にディストラクター再生成 + Insights再生成が走る。

ステップ	モデル	Input tokens	Output tokens	コスト (¥)
ディストラクター再生成	GPT-4o-mini	~300	~100	¥0.02
Word Insights再生成	GPT-4o-mini	~800	~400	¥0.05

- **Pro: ¥0.07 / 回**

導線5: セマンティック検索（Pro, 1クエリ）

ステップ	モデル	Input tokens	コスト (¥)
クエリembedding生成	embedding-3-small	~30	≈¥0

スケール別コスト一覧

導線	ティア	1回 (¥)	10回 (¥)	20回 (¥)	50回 (¥)	100回 (¥)
スキャン	Free	0.8	8	16	41	82
スキャン	Pro	1.6	16	33	82	163
クイズ（最大）	共通	0.03	0.3	0.6	1.5	3
手動追加	Free	0.03	0.3	0.6	1.5	3
手動追加	Pro	0.08	0.8	1.6	4	8
単語編集	Pro	0.07	0.7	1.4	3.5	7
セマンティック検索	Pro	≈0	≈0	≈0	≈0	≈0

月間コスト試算（典型的なユーザー）

Freeユーザー（3スキャン/日 × 30日 = 90スキャン）

項目	回数	単価 (¥)	小計 (¥)
スキャン	90	0.8	72
クイズ（通常¥0）	—	0	0
月間合計			**¥72**

Proユーザー（ヘビーユース）

項目	回数/月	単価 (¥)	小計 (¥)
スキャン	150	1.6	240
手動追加	50	0.08	4
単語編集	30	0.07	2

セマンティック検索	100	≈0	≈0
月間合計			**¥246**

> *Pro月額 ¥500 に対して、API原価は ¥246（粗利率 51%）。*

備考

- Gemini 2.5 Flash の画像トークン数は解像度に依存（圧縮後 ~1,000トークンで概算）
- 1スキャンあたりの抽出単語数は15語で概算（実際は5〜30語程度）
- GPT-4o-miniのバッチ処理により、単語数増でもAPI呼び出し回数は変わらない
- maxOutputTokensは上限設定であり、実際の出力はそれより大幅に少ない
- クイズ導線のコストは通常¥0（ディストラクターはスキャン時に生成済み）
- Word Insightsは単語ごとに逐次処理（1単語1 API呼び出し）
- Embeddings同期のコストは実質無視できるレベル